COMPONENTE CURRICULAR:	Projeto Aplicado IV
NOME COMPLETO DO ALUNO:	Felipe Carlos Campelo
RA:	**10730758**

Atenção: Toda atividade deverá ser feita com fonte Arial, tamanho 11, espaço de 1,5 entre as linhas e alinhamento justificado entre as margens.

PROJETO APLICADO IV

SEGURANÇA VIÁRIA ORIENTADA A DADOS: ANÁLISE E MODELAGEM DOS FATORES ASSOCIADOS A SINISTROS DE TRÂNSITO FATAIS NO ESTADO DE SÃO PAULO

GIT: https://github.com/fccampelo/transito-saopaulo

1 INTRODUÇÃO

A segurança viária é um dos campos em que decisões de política pública produzem efeitos diretos, imediatos e mensuráveis sobre a vida das pessoas. De acordo com a Organização Mundial da Saúde, aproximadamente 1,19 milhão de pessoas morrem todos os anos em decorrência de sinistros de trânsito no mundo, o que faz dessas ocorrências a principal causa de morte entre crianças e jovens de 5 a 29 anos. Mais da metade dessas mortes atinge usuários vulneráveis das vias, isto é, pedestres, ciclistas e motociclistas, e a maior parte delas é considerada evitável mediante intervenções já conhecidas (WORLD HEALTH ORGANIZATION, 2023). Foi nesse contexto que a Assembleia Geral das Nações Unidas instituiu a Década de Ação pela Segurança no Trânsito 2021–2030, que estabelece a meta de reduzir em pelo menos 50% o número de mortes e lesões no trânsito até 2030.

O presente projeto se insere na área de conhecimento da ciência de dados aplicada à mobilidade urbana e à saúde pública. Trata-se de um domínio essencialmente

interdisciplinar, no qual técnicas de análise exploratória, aprendizado de máquina supervisionado, análise espacial e visualização de dados são combinadas com conceitos de engenharia de tráfego e de epidemiologia das causas externas. A literatura brasileira sobre o tema já demonstrou, por exemplo, que a expansão acelerada da frota de motocicletas alterou de forma significativa o perfil das vítimas nas cidades paulistas, deslocando o risco para um grupo específico de usuários das vias (MARÍN-LEÓN et al., 2012). Compreender essa dinâmica exige, hoje, o tratamento sistemático de grandes volumes de registros administrativos.

No Estado de São Paulo, esses registros são consolidados pelo Sistema de Informações Gerenciais de Sinistros de Trânsito, o Infosiga SP, mantido pelo Departamento Estadual de Trânsito (Detran-SP). O sistema integra informações provenientes da Polícia Civil, da Polícia Militar, do Corpo de Bombeiros e das bases de veículos e condutores do próprio Detran, cobrindo os 645 municípios paulistas, e disponibiliza os microdados correspondentes em formato aberto (SÃO PAULO, 2026). Os números publicados evidenciam a dimensão do problema: somente em 2024 foram registrados 135.545 sinistros de trânsito no estado (MOBILIDADE SAMPA, 2025). Na capital, 2025 encerrou com 1.034 óbitos, o segundo maior resultado da série histórica iniciada em 2015, sendo 475 motociclistas e 410 pedestres, com forte concentração entre homens e nas faixas etárias de 20 a 29 anos (AGÊNCIA BRASIL, 2026).

Apesar da qualidade e da abrangência dessa base, o uso predominante que dela se faz ainda é descritivo: painéis, boletins mensais e comparações de totais entre períodos. Esse tipo de leitura responde à pergunta sobre quanto aconteceu, mas não sobre quais combinações de condições tornam um sinistro mais letal, nem sobre onde e quando essas combinações se repetem. Gestores municipais e órgãos estaduais, que operam com orçamento e efetivo limitados, precisam justamente dessa segunda informação para escolher entre alternativas concorrentes de intervenção, como fiscalização de velocidade, redesenho de cruzamentos, sinalização, campanhas educativas ou tratamento de trechos específicos.

O problema selecionado pelo grupo pode ser enunciado da seguinte forma: quais características do sinistro, da via, do momento da ocorrência, dos veículos envolvidos e do perfil das vítimas estão mais fortemente associadas ao desfecho fatal no trânsito do Estado de São Paulo, e em que medida essas características permitem estimar a probabilidade de que um sinistro resulte em morte? Trata-se, portanto, de um problema de classificação supervisionada com forte desbalanceamento de classes, associado a um componente descritivo e espacial que identifica onde os padrões de risco se concentram.

2 MOTIVAÇÕES E JUSTIFICATIVA

A primeira justificativa do projeto é a relevância social do tema. Diferentemente de outros fenômenos analisados por meio de dados, a morte no trânsito é amplamente evitável e existe consenso técnico internacional sobre a eficácia de intervenções específicas. A meta assumida pelo Brasil no âmbito da Década de Ação pela Segurança no Trânsito e do Objetivo de Desenvolvimento Sustentável 3.6 pressupõe capacidade de diagnóstico local: sem identificar quais fatores concentram a letalidade em cada contexto, a redução de 50% até 2030 permanece uma intenção sem plano de execução (WORLD HEALTH ORGANIZATION, 2023).

A segunda justificativa é a existência de dados públicos, oficiais e com granularidade suficiente para sustentar uma análise consistente. O conjunto Sinistros (Infosiga) é publicado sob licença Creative Commons Attribution 4.0, com atualização mensal e dicionário de dados próprio, o que garante ao mesmo tempo viabilidade técnica, reprodutibilidade dos resultados e legitimidade das conclusões (SÃO PAULO, 2026). A série disponível cobre óbitos desde 2015 e sinistros não fatais desde 2019, período longo o bastante para captar tendências e mudanças de perfil das vítimas, e não apenas variações conjunturais.

A terceira justificativa é o potencial de aplicabilidade do produto analítico. Os resultados esperados podem ser utilizados por prefeituras na priorização de trechos e horários para fiscalização e engenharia de tráfego, pelo Detran-SP e por concessionárias de rodovias no direcionamento de campanhas segmentadas por modal e perfil de usuário, e por pesquisadores e imprensa como referência para o acompanhamento das metas estaduais. Um modelo interpretável, que explicite o peso de cada fator, é mais útil nesse cenário do que um modelo apenas acurado, porque a decisão pública precisa ser justificada e comunicada (LUNDBERG; LEE, 2017).

Há, por fim, o interesse formativo do grupo. O conjunto escolhido exige o percurso completo de um projeto de ciência de dados: integração de três tabelas relacionadas com granularidades diferentes, tratamento de inconsistências e de revisões retroativas dos registros, engenharia de atributos temporais e espaciais, modelagem com classes desbalanceadas, avaliação por métricas adequadas a esse cenário e comunicação dos achados para um público não técnico. Esse percurso será conduzido segundo as fases do modelo de referência CRISP-DM, que estrutura o trabalho desde o entendimento do negócio até a implantação (WIRTH; HIPP, 2000).

3 OBJETIVO

3.1 Objetivo geral

Desenvolver um produto analítico, baseado nos microdados públicos do Infosiga SP, capaz de caracterizar e modelar os fatores associados à ocorrência de sinistros de trânsito com vítimas fatais no Estado de São Paulo, de modo a apoiar a priorização de ações de segurança viária por gestores públicos.

3.2 Objetivos específicos

Para alcançar o objetivo geral, o grupo estabelece as seguintes metas:

a) integrar as tabelas de sinistros, vítimas e veículos em uma base analítica única, preservando a rastreabilidade entre os diferentes níveis de granularidade;

b) tratar valores ausentes, inconsistências de preenchimento e registros revisados retroativamente, documentando de forma explícita todos os critérios adotados;

c) realizar análise exploratória sob três recortes complementares: temporal (ano, mês, dia da semana e turno), espacial (município, região administrativa e tipo de via) e de perfil (modal, posição da vítima, sexo e faixa etária);

d) construir atributos derivados relevantes para o problema, tais como turno da ocorrência, indicador de fim de semana e feriado, categoria de via e modal predominante no sinistro;

e) treinar e comparar modelos de classificação para o desfecho fatal, adotando a regressão logística como linha de base e algoritmos baseados em árvores como alternativa, avaliados por métricas apropriadas a classes desbalanceadas, como a área sob a curva de precisão e revocação (HASTIE; TIBSHIRANI; FRIEDMAN, 2009);

f) interpretar os modelos obtidos, traduzindo coeficientes e medidas de importância de atributos em fatores de risco compreensíveis por gestores públicos;

g) identificar a concentração espacial das ocorrências fatais, destacando municípios e tipos de via com maior letalidade relativa;

h) consolidar os achados em um relatório final e em visualizações que sustentem a narrativa dos dados.

4 DESCRIÇÃO DA BASE DE DADOS

4.1 Fonte, forma e período de coleta

O conjunto de dados escolhido é o Sinistros (Infosiga), publicado pelo Departamento Estadual de Trânsito de São Paulo, por meio de sua Diretoria de Segurança Viária, no Portal de Dados Abertos do Estado de São Paulo. Os dados não são coletados especificamente para fins de pesquisa: eles resultam da integração de registros administrativos produzidos por boletins de ocorrência da Polícia Civil e da Polícia Militar, por atendimentos do Corpo de Bombeiros e pelo cruzamento com as bases de veículos e condutores do Detran-SP. Essa origem tem uma implicação metodológica importante, pois linhas já publicadas podem ser revisadas em atualizações posteriores, à medida que os órgãos fornecedores complementam ou corrigem as informações (SÃO PAULO, 2026).

A consolidação é mensal e ocorre por volta do dia 15 do mês subsequente ao de referência. A série histórica de vítimas fatais tem início em 2015; os sinistros não fatais passaram a ser registrados a partir de 2019, com a evolução do sistema, que se encontra atualmente em sua versão 3.0 (MOBILIDADE SAMPA, 2025). A cobertura é estadual e alcança os 645 municípios paulistas, incluindo vias municipais, rodovias estaduais e rodovias federais que cortam o território do estado.

Quadro 1 — Ficha técnica do conjunto de dados

Nome	Sinistros (Infosiga) — Eventos, Vítimas e Veículos envolvidos em Sinistros de Trânsito
Órgão responsável	Detran-SP — Diretoria de Segurança Viária
Publicação	Portal de Dados Abertos do Estado de São Paulo
Cobertura	Estado de São Paulo, 645 municípios
Período	Vítimas fatais desde 2015; sinistros não fatais desde 2019
Atualização	Mensal, por volta do dia 15 do mês subsequente
Formato	Arquivo ZIP contendo arquivos CSV, com dicionário de dados publicado à parte
Licença	Creative Commons Attribution 4.0

Fonte: elaborado pelos autores a partir de São Paulo (2026).

4.2 Estrutura e organização

Os dados são distribuídos em um único arquivo compactado que reúne três arquivos CSV distintos, correspondentes a três níveis de análise relacionados entre si: sinistros, que descreve o evento; vítimas, que descreve as pessoas envolvidas; e veículos, que descreve os veículos envolvidos. Cada arquivo possui, portanto, granularidade própria, com uma linha por evento, por vítima e por veículo, respectivamente. Os arquivos são publicados em duas séries temporais, uma referente ao período de 2015 a 2021 e outra ao período de 2022 em

diante, o que exige a concatenação prévia das séries e a verificação da compatibilidade dos campos entre elas.

Essa organização relacional é uma das razões da escolha do conjunto, pois permite análises em diferentes recortes. É possível, por exemplo, tratar o sinistro como unidade e classificar seu desfecho, ou tratar a vítima como unidade e estudar a gravidade da lesão em função do modal e da posição ocupada no veículo. O Quadro 2 resume as principais informações disponíveis em cada arquivo.

Quadro 2 — Principais informações disponíveis por arquivo

Arquivo	Principais campos
Sinistros	Data, hora, dia da semana e turno da ocorrência; município e código IBGE; região administrativa; logradouro; latitude e longitude; tipo de via (municipal, estadual ou federal); circunscrição da via; responsável pela administração e pela conservação da via; tipo de sinistro primário (colisão frontal, lateral, transversal ou traseira, atropelamento, capotamento, tombamento, choque e engavetamento); gravidade da ocorrência; tipo de registro; ocorrência em local público ou privado.
Vítimas	Sexo e idade da vítima; faixa etária demográfica e legal; nacionalidade; profissão; grau de instrução; meio de locomoção da vítima; posição ocupada no momento do sinistro; gravidade da lesão (fatal, grave, leve ou ileso); data e local do óbito; tempo em dias entre o sinistro e o óbito.
Veículos	Tipo do veículo (automóvel, motocicleta, caminhão, ônibus e bicicleta, entre outros); marca e modelo; cor; ano de fabricação; ano-modelo.

Fonte: elaborado pelos autores a partir do dicionário de dados do Infosiga SP (SÃO PAULO, 2026).

4.3 Volume e natureza das variáveis

O volume é compatível com a proposta do projeto e superior ao de bases utilizadas em exercícios acadêmicos convencionais. Considerando que apenas o ano de 2024 concentrou 135.545 sinistros no estado, a série completa acumula centenas de milhares de eventos e um número ainda maior de registros nos arquivos de vítimas e de veículos, uma vez que um mesmo sinistro pode envolver diversas pessoas e veículos (MOBILIDADE SAMPA, 2025).

Quanto à natureza, predominam variáveis categóricas nominais, como tipo de sinistro, tipo de via e modal, o que exigirá estratégias adequadas de codificação antes da modelagem. Há também variáveis temporais, que permitem a construção de atributos derivados de sazonalidade; variáveis geográficas contínuas, na forma de latitude e longitude, que viabilizam a análise espacial; e um número reduzido de variáveis numéricas, como idade da vítima, ano de fabricação do veículo e tempo em dias entre o sinistro e o

óbito. A variável-alvo do problema de classificação será construída a partir da gravidade registrada, resultando em um indicador binário de desfecho fatal.

4.4 Limitações e aspectos éticos

Três limitações precisam ser explicitadas desde o início. A primeira é a revisão retroativa dos registros, já mencionada, que torna necessário fixar uma versão de referência da base e registrar a data de extração para assegurar a reprodutibilidade dos resultados. A segunda é a descontinuidade metodológica de 2019, quando os sinistros não fatais passaram a ser registrados, o que impede a comparação direta de totais absolutos entre os períodos anterior e posterior a essa mudança. A terceira é o preenchimento incompleto de determinados campos, particularmente os de caráter socioeconômico da vítima, como profissão e grau de instrução, e o georreferenciamento ausente em parte das ocorrências, o que restringirá o uso dessas variáveis a análises complementares.

Do ponto de vista ético e legal, os microdados são publicados de forma anonimizada, sem qualquer elemento que permita a identificação nominal das vítimas, e sob licença que autoriza expressamente a reutilização mediante atribuição da fonte. O tratamento previsto neste projeto é agregado e não busca, em nenhuma etapa, a reidentificação de indivíduos, em conformidade com a finalidade estatística e de interesse público que motivou a publicação da base.

REFERÊNCIAS

AGÊNCIA BRASIL. Capital paulista tem 2º maior número de mortes no trânsito em 2025. Brasília, 25 jan. 2026. Disponível em: https://agenciabrasil.ebc.com.br/geral/noticia/2026-01/capital-paulista-tem-2o-maior-numero-de-mortes-no-transito-em-2025. Acesso em: 31 ago. 2026.

HASTIE, Trevor; TIBSHIRANI, Robert; FRIEDMAN, Jerome. The elements of statistical learning: data mining, inference, and prediction. 2. ed. New York: Springer, 2009.

LUNDBERG, Scott M.; LEE, Su-In. A unified approach to interpreting model predictions. In: CONFERENCE ON NEURAL INFORMATION PROCESSING SYSTEMS, 31., 2017, Long Beach. Advances in Neural Information Processing Systems. Long Beach: NeurIPS, 2017. p. 4765-4774.

MARÍN-LEÓN, Letícia; BELON, Ana Paula; BARROS, Marilisa Berti de Azevedo; ALMEIDA, Solange Duarte de Mattos; RESTITUTTI, Maria Cristina. Tendência dos acidentes de trânsito em Campinas, São Paulo, Brasil: importância crescente dos

motociclistas. Cadernos de Saúde Pública, Rio de Janeiro, v. 28, n. 1, p. 39-51, jan. 2012.

MOBILIDADE SAMPA. Governo de SP lança Infosiga 3.0. São Paulo, 19 set. 2025. Disponível em: https://mobilidadesampa.com.br/2025/09/infosiga-3-0-dados-transito/. Acesso em: 31 ago. 2026.

SÃO PAULO (Estado). Departamento Estadual de Trânsito. Sinistros (Infosiga). São Paulo: Portal de Dados Abertos do Estado de São Paulo, 2026. Disponível em: https://dadosabertos.sp.gov.br/dataset/sinistros-infosiga. Acesso em: 31 ago. 2026.

WIRTH, Rüdiger; HIPP, Jochen. CRISP-DM: towards a standard process model for data mining. In: INTERNATIONAL CONFERENCE ON THE PRACTICAL APPLICATIONS OF KNOWLEDGE DISCOVERY AND DATA MINING, 4., 2000, Manchester. Proceedings. Manchester: Practical Application Company, 2000. p. 29-39.

WORLD HEALTH ORGANIZATION. Global status report on road safety 2023. Genebra: World Health Organization, 2023.